
Etude et modélisation des comportements électoraux

Rapport de Projet de Recherche

Réalisé par :
Raphaël FAURE
Arthur MANCEAU
Alain LUONG



CentraleSupélec

16 avril 2025

Remerciements

Ce projet n'aurait pas pu être réalisé sans l'aide précieuse et constante du Professeur Damien Challet. Il a su se rendre disponible dès que nous en avons besoin, et nous a guidés tout au long de ce travail, qui représentait une première pour beaucoup d'entre nous. Ses conseils, aussi bien sur le traitement des données que sur la modélisation mathématique, nous ont permis d'avancer dans un projet complexe et ouvert. Pour tout ce que vous nous avez transmis durant ce projet, et pour le temps que vous nous avez accordé, nous vous en sommes extrêmement reconnaissants.

Merci également à Madame Véronique Le Chevalier, dont les échanges nous ont permis de remettre notre travail en question et de progresser, tant sur le fond théorique que dans sa forme — cette dernière étant essentielle en entreprise comme en recherche.

Enfin, puisque ce rapport conclut d'une certaine manière notre cursus d'ingénieur à l'École CentraleSupélec, nous souhaitons également remercier l'établissement. En effet, l'école nous a permis, grâce à la richesse de ses enseignements et à son cadre de travail, de nous former aussi bien scientifiquement que personnellement, en nous donnant tous les outils nécessaires pour entrer dans le monde professionnel.

Résumé

Ce projet de recherche propose une double approche pour comprendre et modéliser les comportements électoraux en France, en croisant méthodes statistiques, modélisation physique et apprentissage automatique. À partir des travaux de Thomas Piketty et Julia Cagé d’une part, et de ceux de Jean-Philippe Bouchaud et Christian Borghesi d’autre part, nous explorons les déterminants sociaux, économiques et territoriaux du vote à travers deux cadres théoriques complémentaires : une régression empirique multidimensionnelle et un modèle de champ culturel diffusif inspiré de la physique statistique.

Nous exploitons la base de données électorales communales proposée par Cagé et Piketty, contenant des indicateurs socio-économiques (PIB, diplôme, chômage, propriété, etc.) afin d’analyser les tendances de participation et de vote entre 1848 et 2022. Dans un premier temps, nous validons empiriquement les hypothèses du modèle de Bouchaud et Borghesi sur la corrélation spatiale logarithmique des taux de participation, puis nous en étendons l’application à des élections plus anciennes et nous proposons un enrichissement de la méthode d’estimation de ses paramètres.

Dans un second temps, nous développons une méthode d’analyse de sensibilité en introduisant dans le modèle de Bouchaud et Borghesi des variables socio-économiques, et évaluons l’impact de ces variables sur la moyenne et la variance des taux de participation. Nous mettons également en évidence la dépendance croissante de la participation aux critères de richesse, de diplôme ou de propriété, confirmant les faits stylisés trouvés par Piketty et Cagé. Ce travail établit ainsi un pont entre ces deux approches.

En parallèle, nous explorons des approches complémentaires fondées sur des méthodes de machine learning (XGBoost) puis de deep learning pour prédire les parts de vote des blocs politiques en fonction du contexte local. Cela nous permet de prolonger le travail statistique entrepris par Piketty et Cagé.

Nos résultats confirment la complémentarité entre modélisation physique et analyse empirique des comportements électoraux : ils soulignent la pertinence d’un modèle spatialement diffusif, tout en montrant que l’intégration explicite de variables socio-économiques est indispensable pour rendre compte de la complexité du vote. Cette montée en complexité statistique suggère l’intérêt de formaliser davantage les travaux empiriques initiaux de Piketty et Cagé. Ce travail ouvre ainsi la voie à une modélisation plus unifiée des préférences politiques, articulant dynamiques territoriales et inégalités sociales.

Table des matières

Remerciements	1
Résumé	2
1 Données des élections et observations empiriques	7
1.1 Les données	7
1.2 Pré-traitement des données	7
1.3 Faits stylisés sociaux sur la participations électoral	8
1.3.1 Participation globale aux élections en France	8
1.3.2 Impact des principales variables socioéconomiques sur la participation électorale en France	8
1.3.3 Évolution de la géographie électorale	8
1.4 Faits stylisés statistiques sur la participations électorale	9
1.4.1 Skew et Kurtosis de la participation π	9
1.4.2 Distribution empirique de τ	10
2 Un modèle mathématique du vote	11
2.1 Modèle proposé par Bouchaud et Borghesi	11
2.2 Le modèle retenu	13
2.3 Implémentation du modèle et estimation des paramètres	14
2.3.1 Mise en place	14
2.3.2 Les corrélations spatiales	14
2.3.3 Estimation des paramètres du modèle	15
2.3.4 Une remarque sur la validité du modèle	19
3 Extension du modèle et étude de l'impact des critères socio-économique	20
3.1 Objectif : mettre en lumière l'impact de certaines variables socio-économiques	20
3.2 Méthodologie	20
3.3 Impact des variables socio-économiques au cours du temps	22
3.3.1 Le PIB	22
3.3.2 Le taux de bachelier	23
3.4 L'impact des variables socio-économiques sur les élections récentes	23
3.5 Extension du modèle aux tendances politiques	25
3.5.1 Pour le bloc de gauche	26
3.5.2 Pour le bloc droite / extrême droite	26
3.6 Autres pistes pour l'extension du modèle	27
3.6.1 Introduire un herding factor implicite	27
3.6.2 Introduire d'autres champs	27
3.6.3 En guise de conclusion	28
4 Analyse globale des résultats électoraux	29
4.1 Objectif	29
4.1.1 Prétraitement des données	29
4.2 Régressions linéaires	29
4.3 XGBoost	30

4.3.1	Rappel du modèle	30
4.3.2	Modèle Générale	30
4.3.3	Modèle par année	32
4.3.4	Bilan des méthodes de machine learning	33
4.4	Vers le Deep Learning	33
4.4.1	Intérêts et objectifs	33
4.4.2	Données	33
4.4.3	Première architecture	33
4.4.4	Deuxième approche : GAT	35
5	Conclusion	36
5.1	Bilan du projet	36
5.2	Retour sur expérience	37
	Appendices	40
.1	Table des estimations des paramètres du modèle	40
.1.1	Estimation des paramètres de m_N pour les élections après 1980	40
.1.2	Estimation des paramètres de σ_N^2 pour les élections après 1960	41
.1.3	Variables d'intérêts DL	41

Introduction

Comment expliquer le vote ? Comment expliquer l’abstention ? Que peuvent nous révéler des données électorales sur la société ?

L’étude des comportements électoraux à l’échelle de la société constitue un objet d’étude des sciences sociales. Des travaux en sociologie, par exemple, mettent en avant l’impact persistant de l’environnement social pour expliquer le vote. André Siegfried (1913) [Sie13] propose comme canal de persistance pour expliquer le clivage gauche/droite français la nature géologique des sols (*le granite vote à droite, le calcaire vote à gauche*), reliant ainsi ce phénomène géologique à des géographies et donc des organisations sociales et économiques différentes. Paul Lazerfeld (1944) [Laz44] met en avant l’impact de variables socio-économiques, dites ”lourdes”, qui caractérisent une appartenance sociale (religion, classes sociales) et une appartenance politique.

Toutefois, le fait de voter entre en contradiction avec l’hypothèse de l’individu rationnel, car un calcul coût/avantage montre que le vote n’est pas rentable : il faut prendre du temps pour s’informer sur l’élection et aller voter, mais un vote individuel ne changera pas le résultat du scrutin : le comportement rationnel est celui du ”passager clandestin” (M. Olsen [Ols65]). D’autres explications du vote [Cam+60], plus psychologiques, mettent en avant, ”l’identification partisane” des individus qui, bien qu’elle s’ancre dans le social, le dépasse. L’explication des comportements électoraux fait donc ressortir les limites du rôle explicatif du social. Cette dernière donnée ne suffit pas à pleinement expliquer les votes.

En 2022, Thomas Piketty et Julia Cagé [CP24] entreprennent de rassembler les résultats électoraux de l’ensemble des élections législatives, présidentielles et référendaires françaises soumises au suffrage universel depuis la Révolution française au niveau communal. Ce travail de numérisation et d’analyse fine des données leur permet d’étudier précisément l’impact des déterminants socio-économiques sur le vote [CP23]. Leurs études comportent deux parties : l’étude du taux de participation, puis l’étude des votes pour certaines tendances politiques (divisées en cinq blocs de gauche à droite). Si les auteurs confirment le rôle structurant des déterminants socio-économiques (revenu, capital immobilier, niveau de diplôme, profession, etc), ils montrent que ces variables ne permettent pas, à elles seules, d’expliquer la complexité du comportement électoral. Comme ils le soulignent : « la classe sociale existe et n’a jamais cessé de jouer un rôle déterminant dans la confrontation politique, mais pour être féconde elle doit être envisagée dans une perspective multidimensionnelle et spatiale » (p. 45). C’est précisément cette articulation entre facteurs sociaux et territoriaux qui donne naissance à leur concept central de classe géo-sociale : « la notion pertinente de classe sociale correspond en réalité à une classe géo-sociale (ou socio-spatiale), dont les contours sont en permanence redéfinis par les processus économiques et surtout par les expériences politiques en cours » (p.46). Cette approche permet de rendre compte des différenciations électorales entre classes populaires urbaines et rurales, et de montrer comment l’histoire locale, la structure économique et l’ancrage spatial façonnent ensemble les préférences politiques et les dynamiques électorales.

L’étude des comportements électoraux intéressent aussi certains physiciens à l’image de Jean-Philippe Bouchaud et Christian Borghesi. Avec leurs collaborateurs, ils proposent une modélisation originale fondée sur l’existence d’un champ culturel diffusif, introduit dans une série d’articles récents [Bor09] [BB10] [BRB12]. Dans ce cadre, la décision de chaque électeur (participer ou non, voter oui/non, gauche/droite, etc.) est influencée par trois composantes : une part idiosyncratique, une composante locale à courte portée, et un champ culturel lentement diffusif dans l’espace. Ce champ représente un biais local partagé par les individus d’une même région et évolue selon une équation de diffusion stochastique analogue à celle d’un champ aléatoire en physique statistique. Cette modélisation est justifiée empiriquement par des régularités statistiques observées dans les élections françaises depuis 1992, comme la décroissance logarithmique des corrélations spatiales du taux de participation avec la distance entre communes. Le modèle est ensuite généralisé à un ensemble de 77 élections dans 11 pays européens, confirmant l’universalité de certaines de ces propriétés statistiques.

Ces études n’en restent pas moins marquées par des limites. Du côté de Piketty et Cagé, si les résultats statistiques sont abondants et bien illustrés, les fondements techniques des modèles mobilisés restent peu explicités. Les choix de variables, les formes fonctionnelles des régressions, ou encore la robustesse des résultats sont rarement discutés avec le niveau de rigueur attendu dans une analyse statistique formelle. Cela soulève une question essentielle : dans quelle mesure ces résultats conservent-ils leur validité du point de vue statistique ? Et comment leur apport pourrait-il être enrichi par une approche plus formelle, s’appuyant sur des modèles mathématiques plus poussés ?

À l'inverse, Jean-Philippe Bouchaud et Christian Borghesi proposent une formalisation mathématique complète du processus de décision électorale, à travers un modèle de champ culturel diffusif. Cette approche se distingue par sa précision analytique et ses fondements théoriques solides, mais elle reste déconnectée des grandeurs socio-économiques classiques. Pourquoi ce choix d'abstraction, et dans quelle mesure une telle modélisation rend-elle compte des réalités sociales identifiées par les sciences humaines et sociales ? Peut-on envisager une extension du modèle, incluant explicitement des variables comme le revenu ou le niveau d'éducation ?

En définitive, une piste féconde consisterait à articuler ces deux perspectives : peut-on faire converger la richesse empirique et historique de Piketty et Cagé avec la formalisation dynamique de Bouchaud et Borghesi ? Leurs conclusions sont-elles compatibles, ou au contraire révélatrices de paradigmes opposés dans l'analyse du vote ?

Nous chercherons ainsi à expliquer les résultats électoraux à partir d'un corpus de données socio-économiques en utilisant des méthodes d'apprentissage statistiques et nous détaillerons les valeurs trouvées et leur sens. Nous proposons deux approches pour appréhender ce problème d'apprentissage : l'approche par une régression linéaire puis une approche par apprentissage par renforcement (XG-Boost). Une analyse de sensibilité sur ces modèles permet alors de fournir une mesure de l'impact de déterminants socio-économiques. En parallèle, nous reprendrons la modélisation de Jean-Philippe Bouchaud avec les données précédentes et nous vérifierons sa pertinence pour des données antérieures à 1992. Ensuite, nous souhaitons perturber le modèle à l'aide d'autres variables socio-économiques telles que la population ou le PIB par commune pour quantifier leurs impacts. Enfin, nous voulons enrichir l'approche statistique entreprise par Piketty et Cagé en utilisant des méthodes d'apprentissage.

Chapitre 1

Données des élections et observations empiriques

1.1 Les données

Nous utilisons les données mises à disposition sur le site *Une histoire du conflit politique* et les données mises en ligne par Thomas Piketty et Julia Cagé [CP24]. Ce site regroupe les résultats électoraux de plusieurs élections, notamment les élections présidentielles de la Vème République, l'élection présidentielle de la Deuxième République en 1848, ainsi que divers référendums. Parmi ces référendums, on trouve ceux de 1793 (Constitution de l'an I), 1795 (Constitution de l'an III et décret des deux tiers), 1946 (Constitution de la IVème République), 1992 (traité de Maastricht) et 2005 (projet de constitution européenne). Le site inclut également les résultats des élections législatives de la Deuxième République (à l'exception de 1852), de la Troisième République (à l'exception de 1877), de la Quatrième République et de la Cinquième République (à l'exception de 2024). L'ensemble des résultats électoraux est décliné au niveau de la commune, ce qui signifie que nous disposons des résultats pour chaque commune.

Les résultats ont été obtenus à partir de diverses sources. D'une part, la numérisation des procès-verbaux des élections conservés aux Archives nationales a permis de fournir des données électorales jusqu'à présent indisponible sous forme numérique. D'autre part, les données du Ministère de l'Intérieur, disponibles sous forme numérique pour les élections postérieures à 1993, ont également été utilisées.

Les auteurs des données ont procédé à des classifications politiques que nous reprenons. La première classification est la division "bloc de gauche / bloc de droite", où les variables 'TG' et 'TD' répartissent les voix entre les partis de gauche et les partis de droite, les voix des partis centristes étant divisées équitablement entre ces deux blocs. Une deuxième classification divise les voix en trois blocs : un bloc 'gauche+centre-gauche' ('CGC'), un bloc centre ('C') et un bloc 'droite+centre-droite' ('DCD'). Enfin, une troisième classification répartit les voix en cinq blocs politiques : 'G', 'CG', 'C', 'CD', 'D'. .

La détermination des tendances politiques a été réalisée grâce aux données du ministère de l'intérieur et du journal Le Monde qui décline les résultats par tendance politique pour les élections récentes puis en confrontant les résultats à la presse de l'époque pour les élections les plus anciennes.

1.2 Pré-traitement des données

Ces données représentent une collecte inédite des résultats électoraux à travers les différentes républiques françaises. Cependant, bien qu'elles soient structurées et ordonnées, elles n'en restent pas moins volumineuses. Leur manipulation représente le premier défi que nous avons rencontré. Afin de faciliter leur import sur les notebooks, nous avons choisi de les sauvegarder en .parquet au lieu du .csv. Le format parquet est en effet beaucoup plus efficace que le format csv pour le stockage et la lecture de données volumineuses, car il est binaire, compressé et en colonnes, ce qui permet des lectures plus rapides et des requêtes optimisées.

Ensuite pour travailler avec les données nous effectuons deux transformations. Tout d'abord nous "winsorisons" les données (limite à 1%) pour s'assurer que nous n'avons pas de données extrêmes.

Puis, nous travaillerons avec le logit du taux de participation dans l'étude qui suit. Ce choix est motivé par [BB10] car la modélisation se base sur le logit du taux de participation :

$$\tau = \ln \left(\frac{\pi}{1 - \pi} \right)$$

Pour éviter les problèmes de définition du logit lorsque $\pi = 0$ ou $\pi = 1$, nous considérons que s'il n'y a pas de votant dans une commune donnée, il y a 0,5 votants et si tous les inscrits votent, alors il y a $N - 0,5$ votants.

1.3 Faits stylisés sociaux sur la participations électoral

L'étude de Thomas Piketty et Julia Cagé [CP23] met en lumière les faits stylisés suivants concernant la participation.

1.3.1 Participation globale aux élections en France

Tout d'abord au niveau global, on constate qu'alors que la participation électorale aux élections législatives est en constante augmentation de 1840 aux années 1970. La participation aux élections présidentielles (début en 1965) est au même niveau que celle des législatives des années 1970 ($\approx 70\%$), mais celle des législatives post-1970 a chuté nettement pour aujourd'hui se situer autour 50%.

1.3.2 Impact des principales variables socioéconomiques sur la participation électorale en France

- **Taille des agglomérations :** La participation est plus forte dans les grandes agglomérations que dans les petites, et particulièrement forte dans les villages. Cependant, cette relation était inversée jusqu'aux années 1970.
Voir graphiques 6.3 (p. 274) et 6.4 (p. 275) pour les législatives, et graphiques 7.3 (p. 312), 7.4 et 7.5 (p. 313) pour les présidentielles.
- **Niveau de richesse :** La participation électorale est généralement plus importante dans les communes riches. Cet écart est à un niveau inédit aujourd'hui. Toutefois, cette relation était inversée entre les années 1960 et 2000.
Voir graphique 6.1 (p. 271) pour les législatives et graphique 7.1 (p. 310) pour les présidentielles.
- **Propriété immobilière :** Depuis les années 1960, la participation électorale est plus élevée dans les communes où une proportion importante des ménages sont propriétaires de leur logement.
Voir graphique 6.8 (p. 280) pour les législatives et graphique 7.8 (p. 316) pour les présidentielles.
- **Proportion d'étrangers :** Depuis les années 1960, la participation est plus forte dans les communes où il y a une plus faible proportion d'étrangers.
Voir graphique 6.13 (p. 281) pour les législatives et graphique 7.9 (p. 316) pour les présidentielles.
- **Niveau de diplôme :** La participation est d'autant plus forte que les individus sont diplômés, surtout pour les élections postérieures à 2000.
Voir graphique 6.9 pour les législatives.
- **Catégories socio-professionnelles :** Depuis les années 1990, la participation des cadres a augmenté, tandis que celle des ouvriers a diminué. Cette tendance s'est intensifiée après les années 2000.
Voir graphiques 6.10 (p. 282) et 6.11 (p. 283).

1.3.3 Évolution de la géographie électorale

Au niveau de la géographie électorale, on constate que pour les élections législatives, entre 1876 et 1906, il existe des disparités géographiques de participation importantes, mais le monde rural vote plus que le monde urbain. En 1945, c'est toujours le cas et on constate une uniformisation des comportements au sein du territoire. En 2022, cependant ce constat s'est inversé [cf. cartes 6.1 et 6.2 (page 290-291)].

Pour les élections présidentielles, il existe des disparités importantes entre les départements ainsi que au sein de ces derniers [cf. cartes 7.1 et 7.2 (page 318)].

Enfin les auteurs remarquent que le déterminisme géo-social est de plus en plus explicatif du vote (la part de la variance expliquée avec variables de contrôle augmente au cours du temps) [cf. graphique 6.16 (page 294) pour les législatives et 7.11 (page 320) pour les présidentielles].

1.4 Faits stylisés statistiques sur la participations électorale

Les articles de Bouchaud et Borghesi [BB10] [BRB12] mettent en lumière des faits stylisés de nature statistique sur la participation électorale.

1.4.1 Skew et Kurtosis de la participation π

Tout d'abord, ils remarquent que les séries statistiques de π (taux de participation) pour chaque commune ont une kurtosis et un skew similaires. En effet, ils trouvent en moyenne un skew de ≈ -1.1 . et une kurtosis de ≈ 4.8 .

Nous trouvons qu'il faut nuancer ces résultats car le skew et la kurtosis de ces séries ne sont pas constants au cours du temps. En moyenne, nous trouvons un skew et une kurtosis proches des valeurs trouvées par les auteurs (Pour le skew : $\approx -0,81$ pour les législatives et $\approx -1,19$ pour les présidentielles et pour la kurtosis ≈ 3.12 pour les législatives et ≈ 6.61 pour les présidentielles).

Cependant nous constatons que pour les élections législatives le skew est en augmentation et est devenu positif depuis les années 2000 (sûrement à mettre en lien avec l'effondrement de la participation aux scrutins législatifs dès lors). De même, les élections législatives récentes font état d'une baisse de la kurtosis. Ces valeurs sont relativement stables pour les élections présidentielles. 1.1




FIGURE 1.1 – De bas en haut : sur la première ligne sont considérées les élections législatives, sur la seconde les référendums et sur la troisième les élections présidentielles (T1 uniquement). De gauche à droite : pour chaque bin de population on réalise la moyenne du taux de participation π et son écart-type. On représente ensuite le Skew de cette série et sa kurtosis. Enfin on représente le taux de participation moyen de l'élection (sans tenir compte des bins).

Il est à noter que nous utilisons des élections en partie différentes, même pour les élections récentes, puisque nous considérons uniquement les élections présidentielles, législatives et les référendums et que l'étude [BB10] considère les élections législatives, régionales, municipales, européennes, présidentielles et les référendums à partir des années 1990.

1.4.2 Distribution empirique de τ

Les auteurs mettent ensuite en avant une relative constance dans la distribution empirique de τ , comme en témoigne la figure suivante 1.2 qui représente la série τ centrée et réduite.




FIGURE 1.2 – On représente la distribution empirique centrée et réduite de la variable aléatoire τ (logit du taux de participation pour chaque commune de France) réalisé pour chaque élection (législatives, référendums et présidentielles premier tour). Chaque graphique représente une dizaine d'élections par ordre chronologique. Lecture : si les derniers graphiques montrent des distributions très semblables, on constate qu'à mesure qu'on remonte le temps, cela est de moins en moins vrai.

Remarquons tout de même qu'il y a plus d'uniformité pour les élections récentes que les élections les plus anciennes. En s'intéressant à la distribution empirique de τ , on retrouve en lien avec les résultats de [BB10] que cette dernière n'est pas gaussienne. Grâce au test de Kolmogorov Smirnov ainsi que les QQplot empirique par rapport à la loi normale, on rejette cette hypothèse pour l'ensemble des élections considérées.

Chapitre 2

Un modèle mathématique du vote

2.1 Modèle proposé par Bouchaud et Borghesi

Dans [Bor09] [BB10] [BRB12], les auteurs partent d'une modélisation naturelle qu'un votant est modélisé par une loi binomiale. Pour toute personne i pouvant voter, ils notent φ_i son intention de vote, à savoir aller voter ou non, et Φ_c le seuil au-delà duquel il ou elle va voter. La probabilité que l'individu i vote pour une élection donnée est $\mathbb{P}(\varphi_i > \Phi_c)$. De plus, pour une commune α , ils notent : π_α le taux de participation (théorique) pour une élection, p_α sa réalisation avec $p_\alpha = \frac{V_\alpha}{N_\alpha}$ où V_α (resp. N_α) est le nombre de personnes ayant voté (resp. le nombre d'habitants) ; $\tau_\alpha = \log(\frac{\pi_\alpha}{1-\pi_\alpha})$ son logit. Ils rangent alors les villes par bin de taille et examinent la quantité :

$$C_\tau(r) = \frac{\langle (\tau_\alpha - m_\alpha)(\tau_\beta - m_\beta) \rangle |_{r_{\alpha\beta}=r}}{\langle (\tau_\alpha - m_\alpha)^2 \rangle}$$

où α, β sont des représentants de deux communes et m_α, m_β sont les moyennes des τ pour les communes de même taille que α et β . $C_\tau(r)$ correspond à une corrélation spatiale des taux de participation. Ce que prouve numériquement l'article, c'est qu'il y a une corrélation longue portée entre les taux de participation. En effet, pour des distances intermédiaires ($\ell_c \ll r \ll L$), la corrélation spatiale suit un comportement logarithmique donné par :

$$C_\tau(r) \approx -\Lambda^2 \ln\left(\frac{r}{L}\right),$$

où :

- ℓ_c est une échelle de coupure à courte distance.
- L est la taille linéaire du système (distance maximale entre deux points du système).
- Λ^2 est la pente logarithmique.

La force de ce résultat est que cette fonction de corrélation ressemble à la fonction de corrélation d'un champ diffusif en 2D. En effet, soit ϕ un champs diffusif en 2D qui vérifie une équation stochastique de diffusion :

$$\frac{\partial \phi(R, t)}{\partial t} = D \Delta \phi(R, t) + \eta(R, t),$$

où :

- D est le coefficient de diffusion.
- $\eta(R, t)$ est un bruit stochastique.

La corrélation de ϕ à l'équilibre s'écrit :

$$C_\phi(r) = \frac{\langle \phi(r) \phi(0) \rangle}{\langle \phi(0)^2 \rangle} \approx -\Lambda^2 \ln\left(\frac{r}{L}\right),$$

Les auteurs suggèrent ainsi l'existence d'un champ culturel diffusif $\phi(R, t)$, vérifiant une équation de diffusion stochastique, modélisant les biais locaux influençant les décisions de vote. L'intention individuelle d'un individu i , notée $\varphi_i(t)$, est alors décomposée en trois composantes :

$$\varphi_i(t) = \epsilon_i(t) + \phi(R, t) + \sum_j J_{ij} S_j(t-1),$$

où :

1. $\epsilon_i(t)$ est un terme idiosyncratique propre à chaque individu.
2. $\phi(R, t)$ est le champ culturel local, influençant les individus d'une région donnée, avec η un bruit représentant des événements locaux et D , le coefficient de diffusion, modélisant la transmission culturelle entre communes.
3. $J_{ij}S_j(t-1)$ représente l'effet d'imitation entre voisins.

Ce dernier élément sera écarté de la modélisation car son existence est incompatible avec les valeurs numériques [Bor09]. Ils conservent uniquement le champ culturel $\phi(R, t)$ et le terme idiosyncratique $\epsilon_i(t)$, et s'attachent à modéliser la probabilité de vote d'un individu via la distribution cumulative de la variable ϵ , définie par :

$$P_{>}(x) = \int_x^\infty P(\epsilon) dx',$$

où $P(\epsilon)$ est la densité de probabilité du bruit idiosyncratique. La probabilité qu'un individu vote est donc donnée par $P_{>}(\Phi_c - \phi(R))$. Ainsi, pour une commune α , le taux de participation théorique s'écrit :

$$\pi_\alpha = P_{>}(\Phi_c - \phi(R_\alpha)).$$

Sa réalisation pour la même élection, notée p_α , s'en déduit comme une moyenne empirique bruitée sur la population de la commune :

$$p_\alpha = \frac{1}{N_\alpha} \sum_{i=1}^{N_\alpha} S_i \approx \pi_\alpha + \sqrt{\frac{\pi_\alpha(1-\pi_\alpha)}{N_\alpha}} \xi,$$

où ξ est une variable aléatoire gaussienne standard. Ce terme exprime la *fluctuation statistique* due à la taille finie N_α de la commune.

Afin de faciliter l'analyse, les auteurs font l'hypothèse que ϵ suit une **loi logistique** de paramètre μ (la moyenne) et d'écart-type σ_ϵ , fixée à 1 :

$$P_{>}(x) = \frac{1}{1 + e^{\frac{x-\mu}{\sigma_\epsilon}}}.$$

Le terme $\mu(R)$ peut varier d'une commune à l'autre et représenter des effets locaux (niveau d'information, contexte sociopolitique), qui sont absorbés dans une *composante à courte portée* du champ total. En retranchant ce terme de $\phi(R)$, les auteurs s'assurent que la *fonction de corrélation spatiale* du champ culturel $C_\phi(r)$ est bien normalisée à 1 à petite distance : $C_\phi(r) \rightarrow 1$ lorsque $r \rightarrow 0^+$.

Sous cette hypothèse logistique, le *logit* du taux de participation observé devient :

$$\tau_\alpha = \ln \left(\frac{p_\alpha}{1-p_\alpha} \right) \approx \phi(R_\alpha) + \mu(R_\alpha) - \Phi_c + \sqrt{\frac{1}{\pi_\alpha(1-\pi_\alpha)N_\alpha}} \xi.$$

Lorsque $N_\alpha \rightarrow \infty$, le terme de fluctuation s'annule et l'on retrouve que $\tau_\alpha \approx \phi(R_\alpha) + \mu(R_\alpha) - \Phi_c$. Si l'on suppose $\mu(R_\alpha)$ lentement variant ou négligeable, alors **le champ culturel** $\phi(R)$ devient *directement observable* dans les données à travers τ_α . En effet sous ces conditions, $\tau_\alpha \approx \phi(R_\alpha) + C \propto \phi(R_\alpha)$ d'où :

$$C_\tau(r) \approx C_\phi(r) \approx -\Lambda^2 \ln \left(\frac{r}{L} \right)$$

Cela justifie ainsi son étude empirique à partir du logit des taux de participation. En plus de relier le logit du taux de participation τ_α au champ culturel $\phi(R_\alpha)$, les auteurs analysent en détail la structure de la variance de cette quantité, en introduisant notamment le rôle d'un facteur de "herding" noté h [BRB12]. Ce facteur mesure la tendance de groupes d'individus (famille, voisinage, etc.) à voter de manière corrélée.

Sous cette hypothèse, le taux de participation p_α dans une commune de taille N_α s'écrit comme :

$$p_\alpha \approx \pi_\alpha + \sqrt{\frac{h \pi_\alpha(1-\pi_\alpha)}{N_\alpha}} \xi,$$

où ξ est une variable aléatoire gaussienne centrée réduite. Le terme en h généralise le bruit binomial pour tenir compte d'une variance amplifiée par des effets de corrélation intra-communautaire.

Cette expression conduit, via une approximation logistique, à la relation suivante pour le logit :

$$\tau_\alpha = \ln \left(\frac{p_\alpha}{1 - p_\alpha} \right) \approx \beta (\phi(R_\alpha) + \mu(R_\alpha) - \Phi_c) + \sqrt{\frac{h}{N_\alpha \pi_\alpha (1 - \pi_\alpha)}} \xi,$$

où $\beta = \frac{1}{\sigma_\epsilon}$ est l'inverse de l'écart-type du bruit logistique idiosyncratique.

Dans ce cadre, les auteurs décomposent la variance totale $\text{Var}(\tau) = s_\tau^2$ en trois composantes :

$$s_\tau^2 = \beta^2 \sigma_\phi^2 + \beta^2 \sigma_m^2 + \left\langle \frac{h}{N\pi(1 - \pi)} \right\rangle,$$

où :

- σ_ϕ^2 est la variance du champ culturel diffusif ϕ ,
- σ_m^2 est la variance du terme spécifique à la commune $\mu(R)$,
- le dernier terme est le bruit statistique dû à la taille finie des communes et aux effets de herding.

La comparaison entre ces termes permet d'évaluer l'influence relative des biais locaux et de la structure culturelle globale. Par exemple, pour la France, ils trouvent $\beta^2 \sigma_\phi^2 \approx 0.035$ (constante sur toutes les élections), et un ratio $\sigma_m^2 / \sigma_\phi^2 \approx 1.85$ pour les élections nationales, beaucoup plus élevé pour les élections municipales (jusqu'à 7.7). Ce résultat indique que l'hétérogénéité locale (bruit spécifique aux villes) joue un rôle majeur dans certaines élections, mais que le champ diffusif reste dominant dans la structure des corrélations spatiales.

Enfin, les corrélations spatiales logarithmiques du logit τ , notées $C(r)$, sont bien reproduites par une équation de diffusion stochastique discrétisée :

$$\frac{\partial \phi(R_\alpha, t)}{\partial t} = D \sum_\beta C_{\alpha\beta} [\phi(R_\beta, t) - \phi(R_\alpha, t)] + \eta(R_\alpha, t),$$

avec $C_{\alpha\beta} \propto e^{-r_{\alpha\beta}/\ell_c}$, un noyau d'interaction à portée courte ($\approx 4.5\text{km}$), η un bruit blanc spatio-temporel. Cette équation conduit, à l'équilibre, à une corrélation logarithmique du type :

$$C_\phi(r) \sim -\Lambda^2 \log \left(\frac{r}{L} \right),$$

ce qui justifie théoriquement les observations empiriques faites dans [BB10][BRB12] sur les cartes de France et d'autres pays européens.

2.2 Le modèle retenu

Sous réserve du comportement logarithmique de la corrélation spatiale, le modèle retenu est basé sur ce qui précède. Nous avons utilisé la modélisation suivante :

$$\begin{cases} \varphi_i(t) = \epsilon_i(t) + \phi(R, t) + \mu(R) \\ \tau_\alpha = \ln \left(\frac{p_\alpha}{1 - p_\alpha} \right) \approx \beta (\phi(R_\alpha) + \mu(R_\alpha) - \Phi_c) + \sqrt{\frac{h}{N_\alpha \pi_\alpha (1 - \pi_\alpha)}} \xi \end{cases}$$

On rappelle que cette modélisation est basée sur un regroupement des villes par taille au sens du nombre d'habitants N . L'équation précédente conduit aux moments de τ selon N suivant :

$$\begin{cases} m_N = \beta (\Phi_{\text{th}} + \langle \mu \rangle_N) \\ \sigma_N^2 = \beta (\langle \phi \rangle^2 + \langle \mu^2 \rangle_N - \langle \mu \rangle_N^2) + \frac{h}{N} \left\langle \frac{1}{p(1 - p)} \right\rangle \end{cases} \quad (2.1)$$

Nous avons prolongé cette modélisation en supposant que les termes considérés peuvent dépendre de variables exogènes, absentes de la première modélisation proposée par Bouchaud et Borghesi, telles que des indicateurs socio-économiques.

Les sections et chapitres suivants ont pour objectif de valider ces choix en examinant l'évolution des moments de τ en fonction de la taille N , en proposant des méthodes d'estimation des moments de μ et du paramètre h , ainsi qu'en étudiant l'influence des variations des grandeurs exogènes sur ces moments.

2.3 Implémentation du modèle et estimation des paramètres

2.3.1 Mise en place

Pour mettre en œuvre cette modélisation, nous avons structuré notre traitement autour de plusieurs étapes complémentaires. Dans un premier temps, l'ensemble des scrutins considérés a été rassemblé sous forme de fichiers structurés, contenant pour chaque commune des informations agrégées sur les effectifs électoraux (inscrits, votants, votes exprimés). Une fonction de chargement récursive permet de constituer dynamiquement une base unifiée, facilitant l'analyse multi-élections. Nous avons ensuite appliqué la transformation logistique (logit) aux taux de participation, notée $\tau_\alpha = \ln(p_\alpha/(1 - p_\alpha))$, en prenant soin de régulariser les cas extrêmes ($p = 0$ ou $p = 1$).

L'ensemble des communes a ensuite été géolocalisé, permettant le calcul des distances géographiques entre paires de points. Ces coordonnées ont servi à construire une matrice de corrélation spatiale des variables τ_α entre communes, en fonction de leur distance. Le calcul des moments m_N et σ_N^2 a été effectué en regroupant les communes selon leur taille N , mesurée par le nombre d'inscrits. Plutôt qu'un simple binning logarithmique régulier (par exemple en $\log_{10}(N)$ de pas 0.1), nous avons opté pour une méthode plus robuste statistiquement : les communes sont réparties en classes de taille équivalente en effectif (quantiles), en utilisant les percentiles de la distribution de N . Cette approche garantit que chaque bin contient approximativement le même nombre de communes, ce qui permet de stabiliser l'estimation des moments même dans les extrémités de la distribution, où les communes peuvent être très peu ou très fortement peuplées. Les frontières des bins sont ainsi automatiquement définies à partir des quantiles de N , ce qui permet de concilier une représentativité statistique satisfaisante avec une prise en compte de l'hétérogénéité structurelle des tailles communales.

Cette mise en place a représenté le défi pratique le plus important du projet. En effet, comme dit précédemment, les données sont massives et le code utilisé par Bouchaud et Borghesi n'a pas été publié. Nous avons donc dû implémenter par nous même les fonctions de bins par population mais aussi l'import et le calcul de la matrice des distances inter-communales. Comme nous étions limités en termes de ressources computationnelles, c'était dans premier temps impossible de calculer la matrice de distance et de la manipuler. Nous avons alors utilisé le TPU accessible sur Google Colab ce qui nous a permis de la calculer et de la stocker. Une fois cela fait, nous avons pu appliquer les bins. La limite de cette solution est que nous avons besoin d'un TPU pour l'appliquer et comme l'accès est limité par Google, nous avons dû planifier les calculs de corrélation sur plusieurs jours.

2.3.2 Les corrélations spatiales

Comme vu dans la partie 2.1, le commencement de la modélisation passe par l'étude numérique de C_τ afin de vérifier son caractère logarithmique selon r . Dans un premier temps, nous avons calculé et tracé la corrélation pour différentes élections afin de la visualiser.




FIGURE 2.1 – Résultats des corrélations pour les élections présidentielles de la Ve république et celle de 1848.

L'étude des corrélations, comme indiqué par les figures ci-dessus, suggère que la relation attendue

entre la corrélation et r est vérifiée. Dans un second temps, nous avons donc cherché à estimer les paramètres de la relation :

$$C_\tau(r) \sim -\Lambda^2 \log\left(\frac{r}{L}\right),$$

Nous avons déterminé les paramètres λ , L par régression linéaire, en fixant l'intervalle d'étude à $l_c = 4.5$ km et $L_{\max} = 300$ km. En effet, nous pouvons voir sur les graphiques que la correction commence à vérifier un comportement de droite légèrement avant 10 km et vaut environ 0 au-delà de 300 km. Nous obtenons les résultats suivants sur l'ensemble des élections :

Paramètre	Valeur
λ_{mean}^2	8.84×10^{-2}
L_{mean}	334 km
R_{mean}^2	0.954

TABLE 2.1 – Resultats de l'estimation des paramètres sur l'ensemble des élections présidentielles et référendums ainsi que la moitié des élections législatives

Le R_{mean}^2 est proche de 1 indiquant non seulement que la relation en log explique, en moyenne, 95% des variations de la corrélation sur l'intervalle considéré, mais aussi que cette modélisation est pertinente pour des élections antérieures à 1992, ce qui étend les résultats établis par Bouchaud et Borghesi.

Les valeurs numériques trouvées dans [BB10] sont $\lambda^2 \approx 0.065 \pm 0.01$ et $L \approx 300$ km. Ces valeurs sont du même ordre de grandeur que les nôtres. Ces légères différences peuvent être dues à l'intégration des élections antérieures à 1992.

2.3.3 Estimation des paramètres du modèle

Établir une stratégie d'estimation viable représente un autre défi conceptuel important du projet. En effet, les travaux des physiciens sont lacunaires sur les méthodes d'estimations des moments de τ en fonction de N [Bor09][BB10]. Ainsi, nous avons passé un temps non négligeable à trouver des moyens d'estimer les termes des équations 2.1 et leurs dynamiques selon N . Tout ce qui suit dans cette partie est largement à notre initiative et le fruit d'une réflexion commune menée avec le Prof. Damien Challet.

Pour réaliser une estimation des différents paramètres du modèle, nous devons réaliser des mesures sur τ relativement à la taille de la commune. De fait, nous divisons l'ensemble des communes françaises en environ 200 bins de communes de taille similaire. Les bins sont réalisés à partir de la distribution du nombre d'inscrits dans les communes françaises. Chaque bin contient approximativement 400 communes.

Dans toute la suite, nous considérons le modèle retenu dans la partie 2.2. et nous considérons, sauf mention contraire, l'ensemble des élections de notre corpus de données.

Moyenne de τ

On s'intéresse à la moyenne de tau (moment d'ordre 1) m_N sur l'ensemble des villes dont le nombre d'inscrits est de l'ordre de N , d'où l'indexation en N de la variable (cf. figure 2.1).




FIGURE 2.2 – Moyenne de τ en fonction de la taille de la commune m_N pour les élections présidentielles

On remarque qu'on a des courbes décroissantes. Ces courbes invitent à considérer le modèle suivant

$$m_N = A + BN^c$$

Dans cette équation A représente la composante fixe qui dépend de l'importance de chaque élection ($A = \phi_{th}\beta$). Les paramètres B et c sont supposés être les mêmes pour toutes les élections.

Nous estimons ces trois paramètres par l'algorithme des carrés non-linéaires pour toutes les élections sauf les référendums de 1793 et 1795. Ce modèle ne semble pas bien s'ajuster aux données pour les élections avant 1980. Nous considérons seulement les élections postérieures à cette date. Les estimations des paramètres sont disponibles dans l'annexe 1.

Le paramètre A permet de mettre en évidence le fait stylisé suivant : la participation électorale dépend du type d'élection. Les présidentielles mobilisent plus que les législatives, mais cela est surtout vrai depuis le début des années 1990, en lien avec l'effondrement de la participation électorale aux législatives.

On constate que le comportement des paramètres B et c diffère selon la nature de l'élection. En résumé on peut proposer les modèles suivants :

$$m_N^{pres} \approx \phi_{th} - 0.01\sqrt{N}$$

$$m_N^{leg} \approx \phi_{th} - 0.08N^{0.1}$$

Estimation de l'écart-type τ

On s'intéresse à l'écart-type de tau (moment d'ordre 2) σ_N sur l'ensemble des villes dont le nombre d'inscrits est de l'ordre de N , d'où l'indexation en N de la variable (cf. figure 2.4).

A partir du modèle retenu et des courbes obtenues, on conjecture que :

$$\sigma_N^2 = b_{inf} + \frac{A_1}{N} + \frac{A_2}{N^\omega}$$

Le paramètre $A_1 = h < \frac{1}{p(1-p)} >$, doit dépendre de chaque élection. Le paramètre h ("herding factor") ainsi que les paramètres A_2 et ω sont structurels.

Nous estimons d'abord b_{inf} en faisant tendre $N \rightarrow \infty$. En lien avec le modèle théorique, on est censé avoir : $b_{inf} = \beta < \phi^2 >$. On peut estimer ϕ grâce aux corrélations spatiales : $< \phi^2 > = \lim_{r \rightarrow 0} C_r(\tau)$, ce qui permet d'estimer β :




FIGURE 2.3 – Estimation de b_{inf} et de $< \phi^2 >$

On trouve alors $\beta_{pres} = 0.22$ et $\beta_{leg} = 0.26$.

Ensuite on peut passer à l'estimation par l'algorithme des carrés non-linéaires de A_1 , A_2 et ω . Nous obtenons de bons résultats pour les élections postérieures à 1960.

L'analyse de ces résultats permet de mettre en évidence une rupture dans le comportement des facteurs structurels du modèle avant et après 2010.




FIGURE 2.4 – On représente $\sigma_N^2 - \beta \sigma_\phi^2 - \frac{1}{N} < \frac{1}{p(1-p)} > = \sigma_\mu^2 = \frac{A_2}{N^\omega} = f(N^{-\frac{1}{2}})$. On constate un décalage des courbes progressif au cours du temps (courbe orange vers jaune), ce qui s'interprète ici comme un décalage de ω

Avant 2010, on a un herding factor autour de 1 (on force le herding factor à valoir 1 si la valeur du fit est inférieure à 1, à travers une contrainte sur le paramètre A_1). On constate une relation décroissante $\omega(t) = -at - b$ avec $a > 0, b > 0$. Le paramètre A_2 est compris entre 0 et 5 :


$$\sigma_N^2(t) \approx 0.24 * \sigma_\phi^2 + \frac{1}{N} < \frac{1}{p(1-p)} > + \frac{A_2}{N^{at+b}}$$

Après 2010, le paramètre ω est autour de -0.2 . Le herding factor $h \approx 2$, le paramètre A_2 légèrement


négatif.

$$\sigma_N^2(t) \approx 0.24 * \sigma_\phi^2 + \frac{1}{N} < \frac{2}{p(1-p)} > - \frac{|A_2|}{N^{0.2}}$$

Les estimations des paramètres sont disponibles dans l'annexe 1.



(a) Moyenne et écart-type de τ en fonction de la taille de la commune et ajustement avec le modèle proposé. Premier tour de l'élection présidentielle de 1995.



(b) Moyenne et écart-type de τ en fonction de la taille de la commune et ajustement avec le modèle proposé. Deuxième tour de l'élection présidentielle de 2022.

FIGURE 2.5 – Fit entre les données et le modèle pour deux élections.






FIGURE 2.6 – Estimation des paramètres du moment d'ordre 2 de τ

2.3.4 Une remarque sur la validité du modèle

On constate que la validité du modèle dépend grandement du fait que le taux de participation soit corrélé avec la taille de la ville. Or, cette relation n'est pas stable dans le temps.



(a) Entre les années 1920 et 1960, le vote est plus forte dans les grandes agglomérations que les petites. Source : *Une histoire du conflit politique* (graphique 6.3 page 274)



On constate que pour les élections où la participation est plus forte dans les petites villes que dans les grandes, le modèle renvoie un très mauvais ajustement aux données.

FIGURE 2.7 – Validité du modèle conditionnelle au fait que la participation soit une fonction décroissante de la taille de ville, ce qui n'est empiriquement pas vérifiée pour toutes les élections.

Bilan de cette première partie

Nous sommes partis du modèle de Bouchaud et Borghesi [BB10][BRB12]. Nous l'avons alors vérifié pour des élections antérieures à 1992 ce qui constitue une première extension de leurs travaux. Nous avons ensuite proposé une méthode novatrice d'estimation des moments de τ en fonction N , qui ont montré des résultats empiriques satisfaisants. Enfin, nous avons montré dans la dernière partie que nous trouvons une limite au modèle qui coïncide avec un fait stylisé établi par Piketty et Cagé [CP23].

Chapitre 3

Extension du modèle et étude de l'impact des critères socio-économique

3.1 Objectif : mettre en lumière l'impact de certaines variables socio-économiques

Notre étude précédente nous a permis de valider le modèle proposé dans [BRB12]. Ainsi, nous disposons d'un lien robuste entre la taille de la ville et la moyenne / écart-type des votes. Dans cette partie, nous voulons étendre ce lien pour prendre en compte d'autres indicateurs socio-économiques, en lien avec l'approche proposée dans *Une histoire du conflit politique* [CP23]. On peut voir que ce lien est bien présent sur les deux graphiques suivants, où nous avons représenté la moyenne de τ en fonction de la taille de la commune, pour quatre groupes de communes en fonction de leur PIB (pour les élections de 2022 et 2024) :




FIGURE 3.1 – Moyenne de τ m_N en fonction de la taille de la commune pour quatre groupes de communes différentes séparées par leur position par rapport au PIB nationale. Lecture : On constate que les communes qui participent le moins à la production nationale, courbe violette, ont pour l'ensemble des bin de commune de taille N un taux de participation moyen plus faible.

3.2 Méthodologie

Nous voulons proposer une méthode pour quantifier l'impact d'une variable socio-économique en l'intégrant dans le modèle précédent.

Conceptuellement, on peut supputer qu'une variation des variables socioéconomiques devrait conduire à une modification des estimations précédentes mais l'implémenter représente un défi technique. En

effet, remarquons ici une difficulté qui empêche de simplement ajouter une variable socio-économique dans les équations du modèle. Le modèle repose sur l'agrégation des taux de participation entre communes de même taille. L'ajout d'une variable ne permet plus de prendre la moyenne sur l'ensemble des communes de même taille, car des communes de tailles différentes peuvent partager une même valeur pour cette variable socio-économique nouvellement ajoutée. Cette difficulté représente l'autre grand défi du projet et au cœur du pont entre l'approche de Bouchaud et Borghesi et celle de Piketty et Cagé.

Dans un premier temps, l'ajout d'une autre variable se fera en créant des "double bins". C'est-à-dire en séparant l'ensemble des communes en plusieurs groupes en fonction de leur position par rapport à un critère socio-économique, puis en ajustant le modèle sur ces deux groupes indépendamment.




FIGURE 3.2 – Séparation des communes en double bins et ajustement du modèle

En lien avec les données dont nous disposons, et les conclusions mises en avant par [CP23], nous avons sélectionné les variables socio-économiques suivantes :

- PIB : **perpibratio** percentile de la répartition du PIB communal par habitant pour chaque année de la période 1860-2022.
- Capital immobilier : **capitalratio** capital immobilier (valeur des logements) par habitant en ratio de la moyenne nationale.
- Proportion de bachelier : **perbac** percentile de la distribution de la proportion de bacheliers entre communes (pondérées par leur population 25+).
- Genre : **perpropf** percentile de la répartition de la population en fonction de la proportion de femmes dans la commune.
- Population étrangère : **peretranger** percentile de proportion de personnes de nationalité étrangère pour chaque année de la période 1790-2022.
- Revenu : **revratio** revenu moyen par habitant du département (exprimé en ratio du revenu moyen par habitant de France métropolitaine) pour chacune des années de la période 1860-2022.
- Part de propriétaire : **ppropri** proportion de ménages propriétaires de leur logement dans la commune.
- Chômage : **chom** nombre total de chômeurs (toutes CSP confondues) 25-54 ans.
- Cadre : **cadr** nombre de cadres et professions intellectuelles supérieures (actifs occupés ou chômeurs) 25-54 ans.

Pour chacune de ces données, on sépare les communes en deux groupes par rapport à leur position à la médiane (pour l'année de l'élection considérée). Il faut ensuite déterminer les indicateurs pertinents pour quantifier la différence qu'introduit la séparation autour d'une variable socio-économique. Nous avons considéré les indicateurs suivants :

- $\lambda_m = \frac{m_{lowermedian}}{m_{uppermedian}}$ et $\lambda_\sigma = \frac{\sigma_{lowermedian}}{\sigma_{uppermedian}}$: être une commune en dessous ou au-dessus de la médiane renforce-t-il la moyenne et la volatilité du vote ?
- Le *Mean Absolute Deviation* (MAD) entre les deux séries de données.

- L'indice de dissimilarité : $D = \frac{1}{2} \sum_{i=1}^N \left| \frac{a_i}{A} - \frac{b_i}{B} \right|$
- La distance maximale entre les deux courbes du modèle est ajustée indépendamment sur les deux groupes de communes.

On remarque que cette mesure est empiriquement conditionnelle à la taille de la population et au champ culturel mais est indépendante de la modélisation proposée dans la partie 2. Elle est cependant utile car elle nous permet de quantifier la direction de l'impact d'une variable socio-économique sur nos données.


Le dernier indicateur représente à nos yeux, à supposer que le modèle soit correct, l'indicateur le moins entaché d'irrégularités statistiques puisqu'il capture la dynamique sous-jacente de l'élection. Le seul problème est qu'il ne parvient pas à indiquer un sens dans lequel la variable vient perturber le modèle car les courbes peuvent se croiser et on doit donc prendre la distance maximale en valeur absolue.

3.3 Impact des variables socio-économiques au cours du temps

En appliquant la méthodologie précédente, nous nous intéressons tout d'abord à l'évolution du rôle de certaines variables socio-économiques sur la participation électorale.

3.3.1 Le PIB

On cherche à caractériser l'impact du PIB sur les dynamiques électorales. Comme annoncé dans la section introductive de cette partie, nous trouvons que cette variable a un impact important sur le modèle développé dans le chapitre 2.



- (a) Evolution de λ_m au cours du temps. Lecture : la participation est systématiquement plus forte ($\lambda_m < 1$) dans les communes les plus riches (au sens du PIB) sauf au début des années 2000.
- (b) Evolution de λ_σ au cours du temps. Lecture : les communes les plus pauvres ont sur l'ensemble de l'univers temporel considéré (sauf 1920) connu un vote plus variable ($\lambda_\sigma > 1$) en terme de participation.
- (c) Graphique issu du livre *Une histoire du conflit politique* (6.1. page 271) qui montre uniquement pour les élections législatives l'impact de la richesse (au sens du revenu) sur le taux de participation.

FIGURE 3.3 – Impact au cours du temps du PIB sur la volatilité du vote. Nos résultats sont cohérents avec ceux du livre *Une histoire du conflit politique*

L'analyse de ces graphiques montre que le vote est systématiquement plus important dans les communes les plus riches (au sens du PIB) et il est moins variable. L'évolution temporelle de cette relation montre qu'elle est vraie sur presque l'ensemble des élections considérées (sauf au tournant des années 2000 pour le niveau moyen de participation). En particulier, on retrouve sur les élections récentes une tendance à ce que la participation soit de plus en plus liée au niveau de richesse de la commune et que la variabilité du vote tende à diminuer en fonction du PIB.

3.3.2 Le taux de bachelier




FIGURE 3.4 – Impact au cours du temps du taux de bachelier dans la commune sur la participation. Nos résultats sont cohérents avec ceux du livre *Une histoire du conflit politique*

L'analyse de ces graphiques montre que le vote est plus important dans les communes qui comptent le plus de bacheliers. Depuis les années 2000, ces communes ont un vote qui est moins variable entre elles. Mais il faut faire attention au fait que le nombre de bacheliers a fortement augmenté en France.

3.4 L'impact des variables socio-économiques sur les élections récentes

Nous nous concentrons maintenant sur l'analyse de l'impact des variables socio-économiques sur les élections récentes (après 1990) car pour ces dernières le modèle proposé a été validé empiriquement.




FIGURE 3.5 – $1 - \lambda_m = 1 - \frac{m_{lowermedian}}{m_{uppermedian}}$ indique à quel point être dans le bin relatif au critère socio-économique considéré supérieur va augmenter la moyenne de τ par rapport à être dans le bin inférieur. Lecture : être dans une commune qui dispose d'un percentile de la population ayant le bac supérieur à la médiane pour l'ensemble des communes française l'année de l'élection en question augmente en moyenne de 0.08 le logit du taux de participation conditionnellement au champs culturel et à la taille de la commune pour les élections récentes.

Ces deux graphiques quantifient l'impact global sur la participation de critères socio-économiques. On retrouve bien pour la moyenne de la participation les faits stylisés présentés dans la partie 1, c'est-à-dire que la participation est plus forte dans les communes diplômées, où les ménages sont propriétaires,




FIGURE 3.6 – $1 - \lambda_\sigma = 1 - \frac{\sigma_{lower_{median}}}{\sigma_{upper_{median}}}$ indique à quel point être dans le bin relatif au critère socio-économique considéré supérieur à la médiane va augmenter l'écart-type de τ par rapport à être dans le bin inférieur. Lecture : être dans une commune qui dispose d'une population plus étrangère que la médiane des communes française l'année de l'élection augmente d'environ 0.03 l'écart-type du logit du taux de participation conditionnellement au champs culturel et à la taille de la commune pour les élections récentes.

où la population est riche, qui occupent une place importante dans la production (PIB élevé) et où la proportion de cadres est importante. Le genre de la population n'a que peu d'impact. Au contraire, plus il y a de chômeurs et d'étrangers, plus la participation est faible.

Pour les variabilité des votes, on trouve que la richesse et la propriété sont des facteurs qui tendent à réduire la variabilité de la participation, ce qui constitue un résultat nouveau par rapport à l'étude de [CP23] qui ne s'intéresse pas à la notion de variabilité des taux de participation entre les communes. Au contraire, les communes avec le plus d'étrangers ont une plus grande variabilité dans leur taux de participation.

On peut ensuite s'intéresser à l'indicateur de la distance maximale entre les deux courbes du modèle de la partie 2 ajustées indépendamment. L'analyse de ces courbes met en avant, de manière complémentaire au développement précédent, que la propriété privée et les catégories socio-professionnelles (chômeur, cadre) perturbent fortement les courbes de participation moyenne. Au contraire la proportion d'étranger ou de femme dans la commune a moins d'impact sur l'ajustement du modèle. Le fait d'être propriétaire est le facteur qui perturbe le plus les courbes de l'écart type de la participation entre communes.




FIGURE 3.7 – Ecart maximal entre les deux courbe m_N du modèle ajustées séparément sur les deux groupes de communes indépendantes. Lecture : le fait d’être une commune avec plus de propriétaire que la médiane des communes est associé à une plus grande différence dans la distribution pour des villes de même taille de la participation moyenne que le fait d’être une commune avec plus d’étranger dans sa population que la médiane des communes dans la commune.




FIGURE 3.8 – Ecart maximal entre les deux courbe σ_N^2 du modèle ajustées séparément sur les deux groupes de communes indépendantes. Lecture : le fait d’être une commune avec plus de propriétaire que la médiane des communes est associé à une plus grande différence dans la distribution pour des villes de même taille de la variabilité de la participation que le fait d’être une commune avec plus riche (au sens du PIB) que la médiane des communes dans la commune.


3.5 Extension du modèle aux tendances politiques

Jusqu’à présent on a considéré un *threshold* de participation, si l’intention de vote (qui est une variable continue) y est supérieure, l’individu vote, sinon il ne vote pas. On peut étendre cette approche en considérant un *threshold* ”politique”. Si l’intention est supérieure à ce dernier, alors l’individu vote pour un certain bloc politique, et il ne vote pas pour ce bloc si elle est inférieure (il peut ne pas voter ou alors voter pour un autre bloc).


Cependant, pour que cette modélisation fonctionne, il faut que le vote pour une tendance politique soit décroissant avec le nombre d’inscrits dans la commune, ce qui n’a aucune raison d’être le cas. Ainsi, il convient de prendre du recul sur les résultats qui vont être présentés ici. Empiriquement, on trouve des coefficients d’ajustement linéaire du modèle plus faibles par rapport aux tendances politiques.

3.5.1 Pour le bloc de gauche

On s'intéresse à l'impact des déterminants socio-économiques sur le vote à gauche (le bloc de gauche correspond à l'ensemble des partis de gauche et la moitié des voix des partis centristes).




(a) λ_m pour le vote à gauche en fonction de déterminants socio-économique. Lecture : le PIB augmente le revenu augmente le vote pour le bloc de gauche, le taux de bachelier et de chômeurs le diminue.




(b) λ_σ pour le vote à gauche en fonction de déterminants socio-économique. Lecture : Le chômage diminue grandement la variabilité du vote à gauche

FIGURE 3.9 – Impact de variables socio-économiques sur le vote pour le bloc de gauche (λ)



(a) La proportion d'étranger et de bachelier modifie grandement les paramètres du modèle pour le vote moyen à gauche




(b) La proportion de ménage propriétaire modifie grandement les paramètres du modèle pour la variabilité du vote à gauche


FIGURE 3.10 – Impact de variables socio-économiques sur le vote pour le bloc de gauche ($e_{\max}$)

3.5.2 Pour le bloc droite / extrême droite

Le bloc de droite désigne l'ensemble des votes pour les partis allant de l'extrême droite à la droite conservatrice. Ce bloc n'inclut pas les parties de centre droit.



(a) λ_m pour le vote à l'extrême droite en fonction de déterminants socio-économique. Lecture : Le taux de bachelier augmente le vote ainsi que la proportion d'étranger au contraire, le vote à l'extrême droite est en moyenne moins courant dans les communes plus riches.



(b) λ_σ pour le vote à l'extrême droite en fonction de déterminants socio-économique. Lecture : La proportion d'étranger diminue grandement la variabilité du vote à l'extrême droite

FIGURE 3.11 – Impact de variables socio-économiques sur le vote pour le bloc d'extrême droite (λ)

Le code accessible [ici](#) permet d'explorer pour d'autres tendances politique l'impact des déterminants socio-économiques

3.6 Autres pistes pour l'extension du modèle

Pour étendre le modèle mathématique proposé en partie 2, nous avons de plus deux autres pistes que nous aimerions exploiter.

3.6.1 Introduire un herding factor implicite

Dans un premier temps nous avons vu que l'on pouvait perturber le modèle avec un critère socio-économique et ainsi obtenir deux courbes différentes pour les moments de τ . L'estimation des paramètres sur la courbe de l'écart-type va nous donner une paramètre A_A différent en fonction du PIB, or on a $A_1 = h < \frac{1}{p(1-p)} >$, et donc on peut en déduire un h différent (ou bien une probabilité p moyenne) en fonction du PIB, qu'on désigne alors par h implicite.

Le fait d'avoir un h différent nous permet ensuite de rajouter des paramètres du modèle qui prennent en compte le PIB avant l'estimation.

Le problème de cette méthode est qu'elle ne permet pas d'expliquer les différences constatées dans la moyenne de τ à moins de donner un sens "physique" aux paramètres de l'estimation de m_N et qu'il n'est pas sûr que la modification de h puisse complètement rendre compte des différences observées sur les courbes σ_N^2 . En outre, il est difficile de réaliser des doubles bins équilibrés si on fait de nombreux bins de PIB, même en disposant de 36000 communes. Ainsi on ne pourra pas disposer de nombreuses valeurs de $h(Y)$ pour calibrer la dépendance de h en Y .

3.6.2 Introduire d'autres champs

Notre deuxième idée pour perturber le modèle est d'ajouter un champ culturel d'une autre nature que géographique. Pour cela, nous avons essayé de calculer la fonction de corrélation non pas spatiale mais vis-à-vis du PIB. Nous avons considéré par commune la contribution au PIB national (en %). Comme cette grandeur n'est pas stationnaire, contrairement aux distances inter-villes, nous avons gardé la contribution moyenne des villes au PIB national. Cela présente deux avantages : tout d'abord, ça permet de considérer désormais une valeur de richesse stationnaire ; deuxièmement, comme on peut intervertir somme et moyenne, la somme des contributions moyennes reste égale à 1 donc la contribution moyenne correspond à une contribution. Pour rendre symétrique et positif la comparaison de richesse entre deux villes, on mesure leur écart avec :

$$d(\alpha, \beta) = \left| \log \left(\frac{p_{\alpha}^{\%PIB}}{p_{\beta}^{\%PIB}} \right) \right|$$

où α, β sont deux villes. On fait alors des bins de niveaux de contributions comme pour tracer la corrélation spatiale et on calcule :

$$C_{\tau}(Y) = \frac{\langle (\tau_{\alpha} - m_{\alpha})(\tau_{\beta} - m_{\beta}) \rangle_{d(\alpha, \beta) = Y}}{\langle (\tau_{\alpha} - m_{\alpha})^2 \rangle}$$

Les premiers résultats ne sont pas concluants (comme l'illustre 3.12) et nous n'avons pas pu d'ailleurs expérimenter cela. Avec plus de temps nous aurions pu considérer les contributions sur l'année d'élection et non une valeur stationnaire, mais cela demandait davantage de calculs.




FIGURE 3.12 – Correlation de τ par bin de PIB pour l'élection de 1995

Dans l'idée, ce champ viendrait s'ajouter au "champ culturel" géographique, et on refait ensuite la même étude qui serait cette fois conditionnelle à la géographie, au PIB et en fonction de la taille de la population. Cependant cette méthode présente le désavantage qu'il ne sera plus possible d'isoler l'impact du champ culturel et du champ de PIB.

3.6.3 En guise de conclusion

Les approches présentées dans cette section n'ont pas pu faire l'objet d'une implémentation approfondie faute de temps, mais constituent le prolongement logique de nos travaux.

De manière plus globale, la dépendance entre τ est la taille de la ville (nombre d'inscrits) sur laquelle repose la modélisation est à la fois la force du modèle (puisqu'elle permet de faire ressortir des conclusions intéressantes) et en même temps sa faiblesse car elle nous gêne pour introduire d'autres déterminants socio-économiques. Il faudrait peut-être repartir en amont de la formalisation de tau pour introduire dans la loi de probabilité de la composante idiosyncratique (ou de la variable spécifique à la commune μ) une dépendance en d'autres variables socio-économiques. Une autre piste serait de modifier la diffusion du champs culturel (à partir de son équation pour ajouter des variables explicatives à cet endroit du modèle).

Chapitre 4

Analyse globale des résultats électoraux

4.1 Objectif

L'objectif de cette partie est de complexifier l'approche statistique entreprise par Piketty et Cagé afin de quantifier les informations portées par les variables socio-économiques. En ce sens, nous essayons dans cette partie de mettre en place des techniques de Machine Learning et de statistiques pour essayer d'interpréter les résultats des votes en fonction de toutes les variables disponibles. Nous appliquons d'abord un modèle linéaire avant de tester des modèles plus complexes tels que le XGBoost ou des méthodes de Deep Learning. Nous nous cantonnons d'abord aux élections législatives récentes à partir de 1973 afin d'avoir le maximum de données socio-économiques disponibles.

En quoi cela est-il pertinent dans notre projet ? De prime abord, ce chapitre peut paraître déconnecté du reste. Il n'en demeure pas moins que l'objectif initial des travaux de Piketty et Cagé est d'établir qu'elles sont les variables socio-économiques qui expliquent le vote au fil des années. Comme précisé en introduction, leurs travaux n'ont pas pour objectif de faire une approche formelle comparée à celle empruntée à la physique de la diffusion, mais de quantifier à quel point des variables influent sur les dynamiques de vote. Or le projet s'inscrit dans une volonté de lier ces études tout en les enrichissant. Ainsi, cette complexification statistique a pour but d'enrichir les résultats trouvés par Piketty et Cagé avec des outils statistiques allant de la simple régression linéaire à l'utilisation de modèles d'apprentissage profond.

4.1.1 Prétraitement des données

Nous essaierons d'établir un modèle général sur toutes les élections pour le comparer à un modèle de chaque élection, afin de voir la contribution temporelle. Pour chaque commune française, nous prenons toutes les données disponibles et nous rajoutons les coordonnées géographiques. Le but est de prédire le pourcentage de vote du bloc politique considéré.

4.2 Régressions linéaires

Dans un premier temps, nous allons appliquer la régression linéaire sur nos données :

Métrique	Valeur
Erreur quadratique moyenne (MSE)	0.0168
Racine de l'erreur quadratique moyenne (RMSE)	0.1296
Erreur absolue moyenne (MAE)	0.0974
Coefficient de détermination (R^2)	0.1283
R^2 ajusté	0.1280

TABLE 4.1 – Évaluation des performances du modèle de régression

Les performances du modèle de régression, telles qu'indiquées par les métriques, suggèrent une qualité de prédiction limitée. Bien que les erreurs absolues ($MAE = 0.0974$) et quadratique ($RMSE = 0.1296$) restent relativement faibles en valeur absolue, le coefficient de détermination indique que le modèle n'explique qu'environ 13% de la variance. Ce score faible signifie que le modèle ne parvient pas à bien capturer la structure sous-jacente des données.

4.3 XGBoost

4.3.1 Rappel du modèle

XGBoost (eXtreme Gradient Boosting) est une bibliothèque de machine learning basée sur l'algorithme de *gradient boosting*. Le gradient boosting est une méthode d'ensemble qui combine plusieurs arbres de décision pour construire un modèle fort.

Le fonctionnement général de l'algorithme est le suivant :

- Un premier arbre de décision est entraîné sur les données.
- L'erreur résiduelle (la différence entre les prédictions et les valeurs réelles) est calculée.
- Un nouveau modèle est entraîné pour corriger les erreurs du modèle précédent.
- Ce processus est répété plusieurs fois, chaque modèle suivant cherchant à réduire les erreurs des précédents.
- Chaque arbre supplémentaire est donc ajouté afin de minimiser une fonction de perte.

Les principaux hyperparamètres de XGBoost sont :

- `learning_rate` : taux d'apprentissage, contrôlant la vitesse de mise à jour des poids.
- `n_estimators` : nombre total d'arbres de décision.
- `max_depth` : profondeur maximale des arbres.
- `subsample` : fraction des données d'entraînement utilisée pour construire chaque arbre.
- `colsample_bytree` : fraction des colonnes utilisées pour chaque arbre.
- `scale_pos_weight` : permet de gérer un déséquilibre de classes.

4.3.2 Modèle Générale

Classification

Dans notre étude nous nous focalisons sur trois thèmes : l'extrême-droite, le centre dans le contexte du tripartisme, et le bloc de Gauche dans le contexte du bipartisme. En entraînant toutes les données sur un seul modèle, nous testons d'abord avec une classification Xgboost. Pour chaque bloc d'étude, nous mettons comme label 1 dans chaque ville où ce bloc est en tête, et 0 sinon. Pour l'extrême-droite, voici les résultats de notre modèle :

Métrique	Valeur
Score de Cohen (Kappa)	0.4965
Exactitude (Accuracy)	0.8388
Précision (Precision)	0.5348
Rappel (Recall)	0.6717
Score F1	0.5955
AUC-ROC	0.8943

TABLE 4.2 – Métriques de performance du modèle de classification XGBoost pour l'extrême-droite

Les performances du modèle XGBoost obtenu sont globalement satisfaisantes. L'accuracy atteint 83,9%, indiquant une bonne capacité globale de classification. Le rappel (0,6717) est supérieur à la précision (0,5348), ce qui suggère que le modèle parvient à détecter une proportion raisonnable de cas positifs, mais qu'il commet encore un nombre non négligeable de faux positifs. Le score F1, qui synthétise ces deux aspects, s'établit à 0,5955. Le score AUC-ROC, élevé (0,8943), témoigne d'une bonne capacité de discrimination entre les classes. Enfin, le score de Cohen ($kappa = 0,4965$) indique un accord modéré entre les prédictions du modèle et les classes réelles, au-delà de ce qui serait attendu par le hasard.

Nous affichons maintenant les moyennes des valeurs SHAP en fonction de l'année, ces valeurs indiquent la contribution de chaque features pour chaque ville, nous en faisons une moyenne pour avoir l'importance de chaque variable explicative.




FIGURE 4.1 – Evolution des shap moyen en fonction de l'année pour le modèle de classification générale

Nous pouvons voir dans 4.1 que l'année joue un rôle prépondérant, et toutes les autres variables sont aux alentours de 0.5 ce qui pourrait signifier que ces variables n'expliquent pas bien le vainqueur de l'élection. Une valeur si proche de 0,5 indique que la variable n'a pas un grand impact sur la prédiction de l'une ou l'autre classe.




FIGURE 4.2 – Evolution des shap moyen en fonction de l'année sans l'importance de l'année

Dans 4.2, en nous concentrant sur les autres features, les seules remarquables sont le pourcentage de personnes ayant fait des études supérieures et les prix moyens des biens par commune mais les valeurs restent très faibles. Globalement, les courbes sont difficiles à interpréter.

Régression

On teste maintenant ici la régression XGBoost, on essaye maintenant de prédire les pourcentages des votes du bloc politique.

TABLE 4.3 – Résultats de performance du modèle XGBoost (régression)

Métrique	Valeur
Mean Squared Error (MSE)	0.0089
Root Mean Squared Error (RMSE)	0.0943
Mean Absolute Error (MAE)	0.0649
Coefficient de détermination (R^2)	0.5386
R^2 ajusté	0.5384

Le modèle XGBoost présente des performances sensiblement meilleures que la régression linéaire, avec des erreurs de prédiction réduites et un R^2 plus élevé. Toutefois, le score de R^2 autour de 0.54

indique que seule un peu plus de la moitié de la variance de la variable cible est expliquée par le modèle. Les erreurs absolues et quadratiques demeurent modérées, mais ne permettent pas encore de considérer le modèle comme pleinement prédictif.




FIGURE 4.3 – Evolution des shap moyen en fonction de l'année pour le modèle général

Ici aussi, dans la figure 4.3, l'année joue un rôle prépondérant.




FIGURE 4.4 – Evolution des shap moyen en fonction de l'année sans l'importance de l'année

En enlevant l'année également dans 4.4, nous avons des variations différentes du modèle de classification, la contribution des prix moyen des biens par commune suit une variation équivalente mais celle du pourcentage des études supérieures est inversée.

4.3.3 Modèle par année

Nous allons maintenant entraîner un modèle sur chaque élection.

Classification




FIGURE 4.5 – Évolution des SHAP moyens en fonction de l'année pour le modèle de classification par élection




FIGURE 4.6 – Évolution des SHAP moyen en fonction de l'année pour le modèle de régression par élection

Dans ces modèles, la classification (4.5) présente de manière surprenante uniquement des contributions négatives à presque toutes les variables et les résultats de la régression (4.6) demeurent difficiles à interpréter.

4.3.4 Bilan des méthodes de machine learning

Ces méthodes n'auront pas eu les résultats escomptés. Bien que l'utilisation des shaps values est naturelle pour déterminer la contribution des variables, les courbes obtenues en pratique sont peu concluantes et interprétables. Cependant, les résultats des métriques d'évaluations aussi bien pour le modèle de classification que le modèle de régression suggèrent que les variables socioéconomiques expliquent bel et bien une partie des dynamiques électorales. Un travail de pré sélection des features, en gardant par exemple seulement des features décorrélatées aurait été entrepris avec plus de temps. En effet, cela permettrait de mieux interpréter le rôle de chacune dans les dynamiques électorales.

4.4 Vers le Deep Learning

4.4.1 Intérêts et objectifs

Les sections précédentes montrent que l'analyse des variables socio-économiques à l'aide d'outils classiques de machine learning peut-être limitée mais à la force d'être facilement interprétable. En effet, les relations entre ces variables et les comportements électoraux sont vraisemblablement profondes et non linéaires, ce qui rend difficile leur modélisation par des approches dites "en surface". C'est dans cette optique que nous nous sommes naturellement tournés vers les réseaux de neurones. Le Deep Learning constitue un changement de paradigme : il n'est plus nécessaire d'effectuer un traitement explicite des variables en amont, le modèle apprend directement quelles dimensions conserver ou ignorer. Toutefois, cette puissance d'apprentissage s'accompagne d'une contrepartie majeure : une perte significative en interprétabilité, qui constitue selon nous la principale limite de cette approche.

Cette partie est davantage une partie d'ouverture où nous exposerons nos idées, plutôt qu'une présentation de nos résultats. En effet, faute de temps, nous n'avons pas pu expérimenter en détail cette approche.

4.4.2 Données

Dans la suite, nous considérons les données portant sur les élections présidentielles et législatives allant de 1974 à 2022. Les variables considérées sont détaillées en annexe. Notons que nous conservons dans un premier temps les colonnes 'year', 'longitude', 'latitude', afin d'utiliser cette information géo-temporelle.

4.4.3 Première architecture

L'architecture se doit, autant que possible, d'être pensée dans le sens des travaux précédents. Pour cela nous aimerions intégrer le fait que les rôles des variables socio-économiques s'inscrivent dans un

contexte géographique comme indiqué par Piketty et Cagé. Autrement dit, nous allons séparer les variables précédentes en deux catégories, les variables explicatives et les variables de contexte. Nous voulons à partir de celles-ci prédire le score des 5 blocs au sein de l'élection en confondant législative et présidentielle. Nous proposons un réseau de neurones qui module dynamiquement les variables explicatives à partir d'un vecteur de contexte spatio-temporel. Soit $x \in \mathbb{R}^d$ l'entrée représentant les variables d'une commune. On distingue :

- $x_{\text{context}} \in \mathbb{R}^{d_c}$: les variables de contexte (*e.g.*, longitude, latitude, année),
- $x_{\text{target}} \in \mathbb{R}^{d_t}$: les autres variables explicatives,
- $d = d_c + d_t$.

Le réseau apprend une fonction $g : \mathbb{R}^{d_c} \rightarrow [0, 1]^{d_t}$ qui attribue un poids à chaque variable explicative selon le contexte :

$$g(x_{\text{context}}) = \sigma(W_2 \cdot \text{ReLU}(W_1 x_{\text{context}})),$$

où σ est la fonction sigmoïde appliquée élément par élément, et $W_1 \in \mathbb{R}^{h \times d_c}$, $W_2 \in \mathbb{R}^{d_t \times h}$ sont des matrices de poids apprises.

On applique ensuite une attention multiplicative :

$$\tilde{x} = g(x_{\text{context}}) \odot x_{\text{target}},$$

où $\odot$ désigne le produit élément par élément.

Enfin, la prédiction est obtenue par un réseau de neurones dense :

$$\hat{y} = W_4 \cdot \text{ReLU}(W_3 \tilde{x}),$$

avec $W_3 \in \mathbb{R}^{h' \times d_t}$, $W_4 \in \mathbb{R}^{5 \times h'}$.

Le vecteur $\hat{y} \in \mathbb{R}^5$ est interprété comme des logits représentant les scores des cinq blocs politiques (ED, D, C, G, EG).

La sortie du modèle $\hat{y} \in \mathbb{R}^5$ est transformée en distribution de probabilité par la fonction softmax :

$$\hat{p} = \text{Softmax}(\hat{y}),$$

où $\hat{p} \in \Delta^5$ est un vecteur de probabilité sur les cinq blocs politiques, et Δ^5 désigne le simplexe de dimension 5.

La fonction de perte est composée de deux termes :

- **Cross-Entropy (CE)** : elle évalue la capacité du modèle à prédire correctement la classe majoritaire :

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^N \log \hat{p}_{i, y_i},$$

où $y_i = \arg \max_j p_{i,j}^{\text{true}}$.

- **KL-Divergence** : elle mesure l'écart entre la distribution prédite $\hat{p}$ et la distribution réelle p^{true} :

$$\mathcal{L}_{\text{KL}} = \text{KL}(p^{\text{true}} \parallel \hat{p}) = \sum_{j=1}^5 p_j^{\text{true}} \log \left(\frac{p_j^{\text{true}}}{\hat{p}_j} \right).$$

La fonction de perte totale combinée est donc :

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \beta \cdot \mathcal{L}_{\text{KL}},$$

où β est un coefficient d'équilibrage entre les différentes composantes. Une distance de Wasserstein peut aussi être envisagée.




FIGURE 4.7 – Résultat de la première architecture avec Adam (lr = 5e-4 sur 20 steps)

Les résultats obtenus restent insuffisants à ce stade, mais ils ne sont pas assez approfondis pour permettre d'en tirer des conclusions définitives.

4.4.4 Deuxième approche : GAT

Pour mieux capturer les relations spatiales entre communes, nous imaginons une seconde approche fondée sur les réseaux de neurones graphiques, en particulier les Graph Attention Networks (GAT). Cette architecture permet à chaque nœud (ici une commune) d'agréger dynamiquement l'information provenant de ses voisines les plus proches, avec une pondération apprise par un mécanisme d'attention multi-têtes.

Nous représentons les données sous forme d'un graphe $G = (V, E)$, où chaque sommet $v \in V$ correspond à une commune, et les arêtes E sont construites en reliant chaque commune à ses k plus proches voisines selon la distance géographique euclidienne, définie par leurs coordonnées GPS (longitude, latitude). Le graphe serait obtenu à l'aide d'un algorithme de *k-nearest neighbors*, mais il est également possible d'utiliser un critère de proximité basé sur un seuil de distance. En effet, l'étude de Borghesi et Bouchaud montre que la corrélation spatiale du vote décroît significativement au-delà d'un rayon d'environ 300 km, ce qui suggère qu'un modèle local restreint à une zone de voisinage pourrait suffire à capturer les dépendances pertinentes. Ce type de construction repose sur la définition d'un rayon de coupure fixé, à l'intérieur duquel deux communes sont reliées si leur distance géographique est inférieure au seuil. Cette méthode présente l'avantage d'être plus interprétable et potentiellement plus fidèle aux dynamiques locales, mais elle implique une complexité supplémentaire en termes de stockage des arêtes et de coût mémoire, notamment lorsque le nombre de communes devient important.

Soit $x \in \mathbb{R}^{n \times d}$ la matrice des attributs de nœuds (variables explicatives), $y \in \mathbb{R}^{n \times 5}$ la distribution de vote par commune, et $\text{edge_index} \in \mathbb{N}^{2 \times |E|}$ l'ensemble des connexions dans le graphe. Le modèle GAT imaginé est constitué de deux couches : une première couche à attention multi-tête concaténée, suivie d'une couche de sortie linéaire. Formellement, l'encodage s'écrit :

$$h^{(1)} = \text{ELU}(\text{GATConv}_1(x, \text{edge_index})), \quad \hat{y} = \text{GATConv}_2(h^{(1)}, \text{edge_index}),$$

où $\hat{y} \in \mathbb{R}^{n \times 5}$ sont les logits associés à chaque commune.

La fonction de perte imaginée pour l'entraînement combine deux objectifs : une cross-entropie pour encourager une bonne prédiction de la classe majoritaire, et une distance de Wasserstein unidimensionnelle pour capturer la structure ordonnée des blocs politiques. Cette dernière est définie comme la norme ℓ_1 entre les fonctions de répartition cumulées (CDF) de la distribution prédite $\hat{p}$ et de la vérité de terrain p^{true} :

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \gamma \cdot \|\text{CDF}(\hat{p}) - \text{CDF}(p^{\text{true}})\|_1.$$

L'intégration de cette composante Wasserstein permet de refléter la proximité idéologique entre classes voisines : une confusion entre deux blocs adjacents (ex. centre et gauche) est moins pénalisée qu'un écart entre extrêmes idéologiques. Le modèle serait entraîné sur l'ensemble du graphe par descente de gradient, en utilisant l'optimiseur Adam avec rétropropagation classique. À chaque époque, on évalue la perte globale ainsi que l'exactitude de la prédiction majoritaire. Ce modèle n'a malheureusement pas pu être implémenté au moment du rapport faute de temps.

Chapitre 5

Conclusion

5.1 Bilan du projet

Ce projet de recherche nous a permis d'étudier en profondeur ces deux approches d'analyse du vote et de montrer qu'elles étaient en réalité complémentaires. Cette thématique était nouvelle pour nous et elle représentait clairement un défi tant par sa complexité que par son ouverture.

Tout d'abord, à partir de la base de données électorales de Piketty et Cagé [CP24], nous avons validé et étendu les hypothèses du modèle de Bouchaud et Borghesi [BRB12] sur la corrélation spatiale logarithmique des taux de participation, notamment en l'appliquant à des scrutins plus anciens et en établissant une méthode d'estimation des paramètres comme vu dans le chapitre 2. Cette partie ne s'est pas faite sans difficulté, les données étaient massives, certes plutôt bien organisées mais le volume rendait difficile le calcul des corrélations. De plus, comme aucun code n'était livré avec les travaux de Bouchaud et Borghesi, nous avons dû élaborer et mettre en place tout un traitement de données performant allant de l'intégration des distances inter-communales à aux calculs spatiaux inter-élections ce qui a représenté un temps considérable de travail. (cf. Chapitre 1&2)

Ensuite, en enrichissant ce modèle par l'introduction de variables explicatives issues du contexte socio-économique local - les variables sont issues de la base de données de Piketty et Cagé, nous avons développé une méthode d'analyse de sensibilité aux variations de ces variables qui permet de quantifier leurs effets sur la dynamique électorale. Cette approche hybride et novatrice, que nous avons créée, met en évidence une dépendance croissante des comportements électoraux à des facteurs comme le diplôme, le niveau de vie ou la propriété, ce qui correspond aux faits stylisés identifiés par Piketty et Cagé. Cette approche et ses résultats permettent de faire un pont clair entre la méthode formelle de Bouchaud et Borghesi et les résultats empiriques observés par Piketty et Cagé, ce qui représente l'avancée majeure de ce projet. L'introduction des facteurs socioéconomiques dans le modèle représentait un des objectifs et un de ses principaux défis. (cf. Chapitre 3)

Enfin, l'utilisation d'algorithmes de machine learning et de deep learning pour la prédiction des parts de vote permet de compléter l'approche précédente et les travaux de Piketty et Cagé dans leur livre. En partant cette fois de leur étude empirique, nous avons pu complexifier l'approche statistique établie par les auteurs. Allant de la simple régression linéaire à des architectures complexes de Deep learning, nous avons tenté de quantifier l'explicabilité du vote et de ses dynamiques par ses variables socioéconomiques, prolongeant les résultats des auteurs. En pratique, la complexification statistique n'était pas évidente. En effet, les données étaient volumineuses et l'emploi d'indicateurs parfois dur à interpréter à rendu difficile ce travail statistique. Cette partie n'aura malheureusement pas fourni des résultats concluants. L'ouverture vers des méthodes de deep learning constitue néanmoins une piste de recherche prometteuse. Grâce à leur capacité d'approximation universelle, ces modèles permettent d'évaluer dans quelle mesure les comportements électoraux peuvent être prédits à partir des variables socio-économiques. L'existence d'un modèle performant indiquerait ainsi que l'information contenue dans ces variables est, en elle-même, suffisante pour expliquer une part significative du vote. (cf. Chapitre 4)

L'ensemble de ces résultats montre qu'il est possible de lier l'approche formelle de Bouchaud et Borghesi aux faits stylisés empiriques de Piketty et Cagé. Cette étude suggère des pistes pour d'un côté enrichir le modèle avec un champ d'interaction longue portée avec des variables exogènes so-

cioéconomiques mais aussi de complexifier l’approche empirique afin de quantifier l’information contenue dans les variables socioéconomiques suggérées par Piketty et Cagé.

5.2 Retour sur expérience

Ce travail a été l’occasion de nous confronter à des données complexes, tant par leur nature historique et hétérogène que par leur dimension territoriale. Nous avons pu approfondir nos compétences en traitement de données spatio-temporelles, en analyse statistique et en modélisation mathématique. Le projet dans son ensemble était aussi un défi intellectuel pour nous car il constituait notre première immersion dans un cadre de recherche académique pure. Son caractère ouvert nous a obligés à approfondir les deux approches et à comprendre ce que les auteurs avaient cherché à faire. Forts de cela, nous avons réussi à explorer en profondeur plusieurs pistes bien qu’elles n’aient pas toutes été fécondes. Cela représente pour nous une vraie satisfaction personnelle.

Ainsi au-delà des aspects technico-pratiques, cette expérience nous a enseigné comment la recherche et le traitement de données permettent de mieux comprendre des enjeux pluridisciplinaires et complexes.

References

- [Sie13] André SIEGFRIED. *Tableau politique de la France de l'Ouest sous la Troisième République*. Paris : Armand Colin, 1913.
- [Laz44] Paul LAZARFELD. « The People's Choice: How the Voter Makes Up His Mind in a Presidential Campaign ». In : *Columbia University Press* (1944).
- [Cam+60] Angus CAMPBELL et al. « The American Voter ». In : (1960).
- [Ols65] Mancur OLSON. *Logique de l'action collective*. en. French translation published by Presses universitaires de France, Paris, 1978. Cambridge : Harvard University Press, 1965. ISBN : 0-674-53751-3. URL : <https://www.hup.harvard.edu/catalog.php?isbn=9780674537513>.
- [Bor09] Christian BORGHESI. « Une étude de physique sur les élections ». Thèse de doct. arXiv preprint arXiv:0910.4661, oct. 2009. DOI : [10.48550/arXiv.0910.4661](https://arxiv.org/abs/0910.4661). URL : <https://arxiv.org/abs/0910.4661>.
- [BB10] Christian BORGHESI et Jean-Philippe BOUCHAUD. « Spatial correlations in vote statistics: a diffusive field model for decision-making ». In : *arXiv preprint arXiv:1003.2807* (mars 2010). DOI : [10.48550/arXiv.1003.2807](https://arxiv.org/abs/1003.2807). URL : <https://arxiv.org/abs/1003.2807>.
- [BRB12] C BORGHESI, J-C RAYNAL et J-P BOUCHAUD. « Election Turnout Statistics in Many Countries: Similarities, Differences, and a Diffusive Field Model for Decision-Making ». In : *PLoS ONE* 7.5 (2012), e36289. DOI : [10.1371/journal.pone.0036289](https://doi.org/10.1371/journal.pone.0036289).
- [CP23] Julia CAGÉ et Thomas PIKETTY. *Une histoire du conflit politique. Élections et inégalités sociales en France, 1789-2022*. Paris : Le Seuil, 2023.
- [CP24] Julia CAGÉ et Thomas PIKETTY. *Base de données électorales communales*. <https://www.data-pikettycage.fr>. Consultée en avril 2025. 2024.

Appendices

.1 Table des estimations des paramètres du modèle

.1.1 Estimation des paramètres de m_N pour les élections après 1980

Key	A	B	c	R2	MSE
legislative/1981	2.314391	-0.785343	0.068097	0.908669	0.000939
presidentiel/1981	1.705635	-0.000570	0.613973	0.731555	0.000562
legislative/1986	1.980083	-0.181997	0.144327	0.927452	0.000496
legislative/1988	2.060569	-0.773272	0.068295	0.916211	0.000850
presidentiel/1988	1.739505	-0.000060	0.864442	0.857527	0.000375
referendum/1992	1.965717	-0.555567	0.072693	0.950518	0.000303
legislative/1993	2.129490	-0.817186	0.053376	0.927691	0.000412
presidentiel/1995	1.691159	-0.008345	0.401636	0.954415	0.000244
legislative/1997	1.831475	-0.514722	0.080372	0.965372	0.000248
legislative/2002	1.979069	-0.843336	0.058225	0.858316	0.001251
presidentiel/2002	1.534393	-0.090139	0.205146	0.973084	0.000225
referendum/2005	2.244428	-0.771368	0.065114	0.958567	0.000366
legislative/2007	1.867995	-0.812961	0.067827	0.888641	0.001409
presidentiel/2007	2.048032	-0.006460	0.410800	0.895614	0.000461
legislative/2012	1.789740	-0.805044	0.069408	0.920245	0.001028
presidentiel/2012	1.880846	-0.007833	0.431116	0.928935	0.000693
legislative/2017	1.438877	-0.814083	0.069834	0.861747	0.002105
presidentiel/2017	1.795663	-0.018718	0.337145	0.935370	0.000544
legislative/2022	1.440919	-0.815792	0.074022	0.865831	0.002497
presidentiel/1981/T2	2.388388	-0.076067	0.208089	0.918960	0.000501
presidentiel/1988/T2	2.281491	-0.070191	0.229576	0.936303	0.000544
presidentiel/1995/T2	2.830581	-0.709407	0.077604	0.977812	0.000270
presidentiel/2002/T2	1.938317	-0.084315	0.198267	0.971060	0.000179
presidentiel/2007/T2	2.205416	-0.055801	0.230361	0.935450	0.000409
presidentiel/2012/T2	2.045800	-0.061114	0.240524	0.955975	0.000423
presidentiel/2017/T2	1.752659	-0.087092	0.212419	0.972613	0.000289
presidentiel/2022/T2	1.784446	-0.138756	0.184869	0.984909	0.000207

.1.2 Estimation des paramètres de σ_N^2 pour les élections après 1960

Key	A1	h	A2	omega	R2	MSE
legislative/1962	4.677809	1.000000	0.624058	-0.242811	0.853333	0.000472
presidentiel/1965	7.540055	1.000000	0.881120	-0.330306	0.906960	0.000496
legislative/1967	6.475110	1.000000	0.633000	-0.276642	0.930687	0.000253
presidentiel/1969	6.367391	1.055377	0.917000	-0.375281	0.957613	0.000170
presidentiel/1974	8.064853	1.000000	1.049092	-0.450371	0.960079	0.000174
legislative/1981	5.368595	1.000000	0.917971	-0.440098	0.966291	0.000079
presidentiel/1981	7.209059	1.000000	0.930929	-0.413054	0.957195	0.000146
legislative/1986	6.737227	1.000000	0.986936	-0.497400	0.972284	0.000064
legislative/1988	4.835467	1.000000	0.687866	-0.432004	0.970811	0.000045
presidentiel/1988	7.244301	1.000000	1.774392	-0.584074	0.963378	0.000123
referendum/1992	5.312442	1.000000	0.911634	-0.549083	0.977544	0.000032
legislative/1993	6.452549	1.274740	0.592506	-0.451807	0.975777	0.000038
presidentiel/1995	6.931536	1.000000	2.189981	-0.715179	0.977105	0.000051
legislative/1997	5.043716	1.000000	0.833636	-0.508937	0.986009	0.000020
legislative/2002	4.636423	1.000000	1.143083	-0.682852	0.976943	0.000020
presidentiel/2002	5.615573	1.000000	1.952720	-0.745879	0.982596	0.000023
referendum/2005	9.889789	1.863599	-0.001003	0.152169	0.977148	0.000023
legislative/2007	4.427778	1.000000	0.835265	-0.625014	0.964113	0.000026
presidentiel/2007	16.158973	1.813901	-0.369011	-0.592984	0.975677	0.000046
legislative/2012	8.998581	2.079438	-0.001390	-0.004884	0.975651	0.000019
presidentiel/2012	12.467687	1.610424	0.000582	0.292565	0.968558	0.000045
legislative/2017	8.842521	2.187708	-0.079112	-0.195737	0.967133	0.000017
presidentiel/2017	15.896884	2.225659	-0.349817	-0.373216	0.953722	0.000059
legislative/2022	8.974298	2.227349	-0.058464	-0.118529	0.953006	0.000029
presidentiel/2022	13.747235	2.229090	-0.324428	-0.400146	0.968925	0.000030
presidentiel/1965/T2	7.737696	1.000000	0.882336	-0.337862	0.944692	0.000280
presidentiel/1969/T2	9.557609	1.767477	0.355639	-0.347260	0.925615	0.000212
presidentiel/1974/T2	10.397511	1.000000	1.597077	-0.512784	0.979879	0.000134
presidentiel/1981/T2	9.843722	1.000000	1.385931	-0.492113	0.972192	0.000141
presidentiel/1988/T2	9.067532	1.000000	2.577786	-0.676836	0.982057	0.000072
presidentiel/1995/T2	7.469022	1.000000	1.734991	-0.653273	0.982376	0.000043
presidentiel/2002/T2	7.253771	1.000000	3.045811	-0.844198	0.987505	0.000022
presidentiel/2007/T2	9.011797	1.000000	2.793223	-0.808327	0.979859	0.000047
presidentiel/2012/T2	39.199015	4.999996	-22.270595	-0.965646	0.974482	0.000042
presidentiel/2017/T2	13.859678	2.202292	-0.169218	-0.335557	0.973106	0.000034
presidentiel/2022/T2	15.290291	2.545362	-0.290530	-0.330979	0.974373	0.000030

.1.3 Variables d'intérêts DL

Variable	Description
capitalimmo	Le capitalimmo représente la valeur estimée du capital immobilier d'une commune : $\text{capitalimmo} = \text{capitalratio} \times \text{pop}$. Le capitalratio est un coefficient de répartition du capital immobilier entre les communes d'un même département. Il est utilisé pour estimer la valeur du capital immobilier communal à partir d'un total départemental. Il compare le prix moyen des biens immobiliers d'une commune à la moyenne des prix immobiliers dans l'ensemble du département, pondérée par la population. Ainsi, il permet de répartir le capital immobilier départemental entre ses communes en fonction de leur attractivité immobilière relative.
pop	Population totale de la commune.
pibratio	PIB communal par habitant i en % de la moyenne nationale.
revtot	Revenu total en i en ratio de la moyenne nationale.
petranger	Pourcentage d'étrangers dans la commune.
pbac	Proportion des personnes ayant obtenu le baccalauréat ou poursuivi des études supérieures.
pouvr	Proportion d'ouvriers dans la population active.
pchom	Proportion de chômeurs dans la population active.
npropri	Nombre de propriétaires dans la commune.
nodiph	Nombre d'individus sans diplôme.
psup	Proportion des personnes ayant un diplôme supérieur au baccalauréat.

TABLE 1 – Description d'un sous-ensemble des variables explicatives utilisées dans le modèle